

Prédiction de l'Occlusion Faciale

Ensemble de réseaux convolutifs sous métrique équilibrée par genre

Kamal Belmajdoub Khalil Regaieg Mohamed Ali Feniche

Groupe : Join the Club — N° 17 | Data Challenge Idemia | Juin 2026

Code et reproduction : github.com/regkhalil/Data-Challenge

Résumé. Nous prédisons le pourcentage d'occlusion d'un visage ($\in [0,1]$) sur des images 224×224, évalué par une MSE pondérée équilibrée entre genres. Notre solution finale est un **ensemble de sept réseaux convolutifs** (ConvNeXt-Large, ConvNeXtV2-Base, ConvNeXt-Base et EfficientNet-B4, entraînés sur plusieurs graines aléatoires) combinés par un mélange pondéré de deux sous-ensembles. La fonction de perte reproduit exactement la métrique officielle, et un échantillonnage pondéré corrige le double déséquilibre (occlusions fortes rares, genre). L'ensemble atteint un score intérimaire de **0,00112**, contre 0,0011–0,0018 pour les modèles individuels. Nous discutons des approches écartées (dégradation synthétique sur-apprenant la validation, calibration par genre rendue impossible par l'anonymisation du genre de test) et des limites de l'approche (coût de calcul, complexité, nombre d'hyperparamètres).

Problème et Métrique

On dispose d'images de visages 224×224 et l'on prédit un score d'occlusion continu $p \in [0,1]$. La métrique officielle est une erreur quadratique *pondérée*, moyennée par genre avec une pénalité de disparité :

$$w_i = \frac{1}{30} + GT_i, \quad \text{Err}_g = \frac{\sum_i w_i (p_i - GT_i)^2}{\sum_i w_i},$$

$$\text{Score} = \frac{\text{Err}_F + \text{Err}_M}{2} + |\text{Err}_F - \text{Err}_M|.$$

Deux conséquences structurent toute notre approche. D'abord, le poids w_i rend un échantillon $GT = 1$ environ **31×** plus important qu'un échantillon $GT = 0$: les rares cas d'occlusion forte dominent le score. Ensuite, le terme $|\text{Err}_F - \text{Err}_M|$ impose que les deux genres soient également bien calibrés.

Données

L'ensemble d'entraînement compte 100 000 images, le test 29 980. La distribution de l'occlusion est très asymétrique : moyenne 0,083, médiane 0,05, et **69 %** des échantillons sous 0,1. Le genre est déséquilibré (32,4 % femmes, 67,6 % hommes). Crucialement, le **genre du jeu de test est masqué** (colonne absente, remplacée par $\mathbf{x}$), ce qui interdit toute calibration par genre a posteriori et confine ce levier à la phase d'entraînement.

Méthode

Architecture

Chaque modèle est un *backbone* `timm` [1] (`num_classes=0`) suivi d'une tête de régression FC [512,128] $\rightarrow 1$ avec ReLU, Dropout (0,3) et Sigmoid finale. Nous explorons ConvNeXt-Base/Large [2], ConvNeXtV2-Base [3] et EfficientNet-B4 [4].

Perte = métrique

La perte d'entraînement reproduit exactement la MSE pondérée ci-dessus. En cas de mini-batch mono-genre (atténué par le sampler), on repasse à la MSE pondérée globale. Cette identité entre objectif d'entraînement et critère d'évaluation supprime tout écart d'optimisation qui surviendrait avec une MSE ou une perte Huber classique [5].

Échantillonnage pondéré

Pour corriger simultanément la rareté des occlusions fortes et le déséquilibre de genre, le poids d'échantillonnage est

$$s_i = \left(\frac{1}{30} + GT_i \right) \times \frac{N}{2N_{g(i)}} \times \text{male_boost}.$$

Le facteur `male_boost` = 2,5 (modéré) agit sur le terme de disparité. Un découpage stratifié 80/20 sur (genre × tranche d'occlusion) évite tout biais d'ordre.

Augmentation et inférence

Augmentations : miroir horizontal, *ColorJitter* (0,3/0,3/0,2), rotation $\pm 20^\circ$, flou gaussien ($p = 0,4$). Nous excluons *RandomErasing* (il simulerait une occlusion = fuite de label). Optimiseur AdamW, *scheduler* cosinus, 30 époques ; le *learning rate* est réduit à 3×10^{-5} pour les *backbones* ConvNeXtV2 (FCMAE) qui divergent à 10^{-4} . L'inférence utilise une augmentation au test (TTA) à 15 passes moyennées.

Solution Finale : Ensemble

La solution soumise combine **sept modèles** en deux temps :

- **ENS4** = moyenne de quatre ConvNeXt forts : ConvNeXtV2-Base, ConvNeXt-Large (graine 123), ConvNeXt-Large (graine 999), ConvNeXt-Base (graine 456).
- **s6** = moyenne de trois modèles diversifiants : ConvNeXt-Base (graines 42 et 123) et EfficientNet-B4.
- **Final** = $0,55 \cdot \text{ENS4} + 0,45 \cdot \text{s6}$.

La diversité (architectures et graines distinctes) réduit la variance des prédictions : l'ensemble bat nettement chaque modèle pris isolément.

Table 1 – Scores de validation par modèle et leaderboard intérimaire des ensembles.

Modèle / Ensemble	Détail	Score
ConvNeXt-Large (g. 999)	val	0,0011
ConvNeXt-Large (g. 123)	val	0,0011
ConvNeXtV2-Base (g. 123)	val	0,0014
ConvNeXt-Base (g. 123)	val	0,0016
ConvNeXt-Base (g. 42)	val	0,0016
ConvNeXt-Base (g. 456)	val	0,0018
EfficientNet-B4 (g. 123)	val	0,0017
ENS3 (3 ConvNeXt)	leaderboard	0,00115
s6 (base+B4)	leaderboard	0,00116
champions (ENS3+s6)	leaderboard	0,00113
Final (ENS4+s6)	leaderboard	0,00112

Approches Écartées et Discussion

Baseline classique (vision par ordinateur). En amont de l'approche apprentissage, une heuristique déterministe sans entraînement a été développée : normalisation CLAHE sur le canal Y de YCrCb, masque de peau primaire sur les chrominances ($\text{Cr} \in [133,173]$, $\text{Cb} \in [77,127]$), masque HSV adaptatif secondaire, filtre texture Laplacien avec exclusion anatomique (yeux, bouche), estimation de l'occlusion par fraction non-peau dans un ROI circulaire central. Cette approche totalement généralisée atteint un plafond de $\sim 0,023$ sur la métrique : la complexité sémantique des occlusions (écharpes, mains, cheveux) et les artefacts de compression rendent insuffisant tout détecteur

de peau fixe. Ce résultat a validé le passage à l'apprentissage profond.

La validation peut mentir. Une recette à dégradation synthétique (occlusions artificielles, pondération de queue agressive, `male_boost` mis à l'échelle du GT) a atteint le *meilleur* score de validation (0,00129) mais le *pire* score de test (0,00218) : sur-apprentissage net. La recette n'est propre à (sans ces artifices, `male_boost` = 2,5 modéré) généralise bien mieux. Nous nous sommes donc fiés au leaderboard, pas à la validation seule.

Calibration par genre impossible. Le genre du test étant masqué (`gender=x`), aucune correction par genre n'est applicable a posteriori. Un *scaling* global (α, β) ajusté sur la validation n'apporte que 0,9 %, confirmant que les modèles propres sont déjà bien calibrés.

L'architecture compte. ViT-Base, Swin-Base et EfficientNetV2-M sont nettement inférieurs (val > 0,0018) ; ajouter le ViT *dégrade* l'ensemble (0,00121). En revanche, EfficientNet-B4 à *faible* poids apporte une décorrélation utile et figure dans la solution finale.

Plateau de pondération. L'optimisation fine du mélange (ratio des deux sous-ensembles, poids intra-ENS4) plafonne à 0,00112 : le gain marginal provient de nouveaux modèles diversifiés, non des poids.

Limites

Coût de calcul. La solution agrège sept réseaux profonds, chacun entraîné 10–20 h sur une RTX 3090, plus une inférence TTA×15 de l'ordre de 1–2 h par modèle. Le coût total (entraînement et inférence) est élevé et peu adapté à un déploiement temps réel.

Complexité et hyperparamètres. ConvNeXt-Large compte ~200 M paramètres ; l'ensemble est lourd en mémoire et en stockage. Plusieurs hyperparamètres demandent un réglage (`male_boost`, *learning rate* par *backbone*, poids d'échantillonnage, ratio de mélange).

Robustesse. Le score intérimaire est calculé sur une distribution intermédiaire entre train et test ; le score final, sur la seule distribution de test, peut différer.

Perspectives

Une **distillation** de l'ensemble vers un unique réseau réduirait drastiquement le coût d'inférence en conservant l'essentiel de la performance. Un mélange pondéré par **incertitude** (plutôt qu'à poids fixes) et l'ajout d'architectures réellement décorrélatées mais performantes constituent les pistes les plus prometteuses pour franchir le plateau actuel.

Reproductibilité

Toutes les étapes (entraînement des sept modèles, génération des prédictions TTA, mélange final) sont documentées dans le README du dossier `model-training/`, et les approches explorées dans `experiments/EXPERIMENTS.md`.

Références

- [1] Ross Wightman. Pytorch image models. <https://github.com/rwightman/pytorch-image-models>, 2019.
- [2] Zhuang Liu, Hanzi Mao, Chao-Yuan Wu, Christoph Feichtenhofer, Trevor Darrell, and Saining Xie. A convnet for the 2020s. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11976–11986, 2022.
- [3] Sanghyun Woo, Shoubhik Debnath, Ronghang Hu, Xinlei Chen, Zhuang Liu, In So Kweon, and Saining Xie. Convnext v2 : Co-designing and scaling convnets with masked autoencoders. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 16133–16142, 2023.

- [4] Mingxing Tan and Quoc V. Le. Efficientnet : Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning (ICML)*, pages 6105–6114, 2019.
- [5] Ilya Loshchilov and Frank Hutter. Decoupled weight decay regularization. *International Conference on Learning Representations (ICLR)*, 2019.